OS lab5实验报告

实验准备

将之前实验的代码添加到 `LAB5` 源码中。

`proc.c` 的 `alloc_proc` 函数填充部分：

代码块

```
// LAB4原有
proc->state = PROC_UNINIT;                  // 初始化进程状态为未初始化
proc->pid = -1;                             // 初始化进程ID为-1（无效ID），后续通过get_id()来分配有效pid
proc->runs = 0;                             // 初始化运行次数为0
proc->kstack = 0;                           // 初始化内核栈为0（空指针），后续通过setup_kstack()为进程分配实际的内核栈空间
proc->need_resched = 0;                     // 初始化不需要重新调度
proc->parent = NULL;                        // 初始化父进程指针为NULL
proc->mm = NULL;                            // 初始化内存管理结构指针为NULL
memset(&(proc->context), 0, sizeof(struct context)); // 初始化上下文结构体，全部设为0，为后续保存现场做准备
proc->tf = NULL;                            // 初始化陷阱帧为NULL
proc->pgdir = boot_pgdir_pa;                // 初始化页目录表基址为boot_pgdir_pa
proc->flags = 0;                            // 初始化进程标志为0
memset(proc->name, 0, PROC_NAME_LEN + 1);   // 初始化进程名称数组全部清零，后续通过set_proc_name()设置具体的进程名称
list_init(&(proc->list_link));
list_init(&(proc->hash_link));

// LAB5新增
proc->wait_state = 0;       // 设置进程的等待状态为0，表示进程当前不在等待状态
proc->cptr = NULL;          // 初始化子进程指针为NULL
proc->optr = NULL;          // 初始化较年长兄弟进程(older sibling pointer)指针为NULL
proc->yptr = NULL;          // 初始化较年轻兄弟进程(younger sibling pointer)指针为NULL
```

`proc.c` 的 `do_fork` 函数填充部分：（在LAB4基础上做了改动）

代码块

```
// 1) 分配进程控制块
```

```
    if ((proc = alloc_proc()) == NULL) {
        goto fork_out;
    }

    // LAB5: 设置父进程，并确保父进程的 wait_state 为
    proc->parent = current;
    // 确保当前进程的等待状态为0（不在等待子进程）
    // assert(current->wait_state == 0);  // 可选的断言检查

    // 2) 分配子进程的内核栈
     if (setup_kstack(proc) != 0) {
        goto bad_fork_cleanup_proc;
    }

    // 3) 复制/共享内存管理信息
    if (copy_mm(clone_flags, proc) != 0) {
        goto bad_fork_cleanup_kstack;
    }

    // 4) 复制上下文（含 trapframe），并设置返回路径
    copy_thread(proc, stack, tf);

    // 5) 分配唯一 pid
    bool intr_flag;
    local_intr_save(intr_flag);  // 关中断，保证原子性
    {
        proc->pid = get_pid();

        // 挂到哈希表，便于 O(1) 按 pid 查找
        hash_proc(proc);

        // LAB5: 使用 set_links 建立进程关系并插入链表
        set_links(proc);
    }
    local_intr_restore(intr_flag);  // 恢复中断

    // 6) 唤醒子进程，使其可调度（会把 state 置为 PROC_RUNNABLE）
    wakeup_proc(proc);

    // 7) 父进程得到子进程的 pid 作为返回值
    ret = proc->pid;
```

`proc.c` 的 `proc_run` 函数：

```
代码块
```

```c
void proc_run(struct proc_struct *proc)
{
    // 只有当要运行的进程不是当前进程时，才需要执行切换
    if (proc != current)
    {
        /* 关闭本地中断，并保存当前中断标志状态 */
        unsigned long irq_flags;
        local_intr_save(irq_flags);

        /* 保存原来的当前进程指针，将 current 切换为目标进程 */
        struct proc_struct *prev = current;
        current = proc;

        /* 记录该进程被调度运行的次数（用于统计或调度算法） */
        current->runs++;

        /* 切换页表，加载新进程的地址空间 */
        lsatp(current->pgdir);

        /*
         * 进行上下文切换：
         * 保存 prev 的寄存器上下文，恢复 current 的寄存器上下文。
         * 当 CPU 再次切换回 prev 时，switch_to 函数会从这里继续执行。
         */
        switch_to(&prev->context, &current->context);

        /* 恢复之前保存的中断标志状态 */
        local_intr_restore(irq_flags);
    }
}
```

`trap.c` 的填充部分：在 `LAB3` 的基础上做了改动，删去了 `sbi_shutdown()`，同时设置了调度标志，保证程序能正常执行直至结束。

代码块

```c
case IRQ_S_TIMER:{
        /* LAB5 GRADE   YOUR CODE :  */
        /* 时间片轮转:
        *(1) 设置下一次时钟中断（clock_set_next_event）
        *(2) ticks 计数器自增
        *(3) 每 TICK_NUM 次中断（如 100 次），进行判断当前是否有进程正在运行，如果有则标记该进程需要被重新调度（current->need_resched）
        */

        // (1) 设置下一次时钟中断
```

```
        clock_set_next_event();

        // (2) ticks 计数器自增
        ticks++;

        // (3) 每 TICK_NUM 次中断，标记进程需要重新调度
        if (ticks % TICK_NUM == 0) {
            if (current != NULL) {
                current->need_resched = 1;
            }
        }
        break;
    }
```

另外，在 `trap.c` 中添加处理页面错误的代码：（以通过两个 `fault` 样例）

代码块

```
static int
pgfault_handler(struct trapframe *tf) {
    uintptr_t addr = tf->tval;

    if (current == NULL) {
        print_trapframe(tf);
        panic("page fault in kernel!");
    }

    if (current->mm == NULL) {
        print_trapframe(tf);
        panic("page fault in kernel thread!");
    }

    // 对于非法访问（如faultread访问地址0），返回错误
    // 让exception_handler杀死进程
    return -E_INVAL;
}

void exception_handler(struct trapframe *tf)
{
    int ret;
    switch (tf->cause)
    {
    // ... 其他 case 保持不变 ...

    case CAUSE_FETCH_PAGE_FAULT:
        if ((ret = pgfault_handler(tf)) != 0) {
```

```
            cprintf("Instruction page fault\n");
            print_trapframe(tf);
            if (current != NULL) {
                do_exit(-E_KILLED);
            } else {
                panic("kernel page fault");
            }
        }
        break;

    case CAUSE_LOAD_PAGE_FAULT:
        if ((ret = pgfault_handler(tf)) != 0) {
            cprintf("Load page fault\n");
            print_trapframe(tf);
            if (current != NULL) {
                do_exit(-E_KILLED);
            } else {
                panic("kernel page fault");
            }
        }
        break;

    case CAUSE_STORE_PAGE_FAULT:
        if ((ret = pgfault_handler(tf)) != 0) {
            cprintf("Store/AMO page fault\n");
            print_trapframe(tf);
            if (current != NULL) {
                do_exit(-E_KILLED);
            } else {
                panic("kernel page fault");
            }
        }
        break;

    // ... 其他 case 保持不变 ...
    }
}
```

练习一

代码如下：

代码块

```
    /* --- begin inserted code --- */
/*
```

```
 * (6) 建立用户态 trapframe 和初始寄存器
 *
 * 目标:
 *  - sp 指向用户栈顶（USTACKTOP）
 *  - epc 指向 ELF 的入口（elf->e_entry）
 *  - status: 清 SPP（返回后进入用户态），置 SPIE（sret 返回后允许中断）
 *
 */
/* set user stack pointer */
tf->gpr.sp = (uintptr_t)USTACKTOP;

/* set program entry point (sepc) */
tf->epc = (uintptr_t)elf->e_entry;

/* set return value for exec in user mode (argc = 0) */
tf->gpr.a0 = 0;

/* Adjust sstatus: clear SPP (so sret goes to user-mode), set SPIE (enable
interrupts after sret) */
tf->status = (sstatus & ~SSTATUS_SPP) | SSTATUS_SPIE;
```

设计实现过程

1. `load_icode` 首先为当前进程创建一个新的 `mm_struct`，并调用 `pgdir_alloc_page/vmm_map/phdr` 等逻辑，按 ELF 的 program header 把代码段、数据段映射到进程的页表中。同时分配用户栈（一般大小为若干页），栈顶地址固定为 `USTACKTOP`。
2. 遍历 ELF 的 program segments（`PT_LOAD`），把数据按 p_vaddr 复制到用户页，同时清空 bss 区域。这保证了用户程序进程的虚拟空间布局与 ELF 所要求的一致。
3. **正确初始化 trapframe**
   - **设置用户栈指针 SP** `tf->gpr.sp = USTACKTOP;`
   - **设置 EPC = ELF 入口地址** `tf->epc = elf->e_entry;`

     这样用户进程第一次执行的就是 ELF `_start`。
   - **设置 trapframe.status**

     `tf->status = (sstatus & ~SSTATUS_SPP) | SSTATUS_SPIE;`
   - **SPP = 0** ⇒ `sret` 之后进入用户态
   - **SPIE = 1** ⇒ 允许用户态中断在返回后开启
4. 在 load_icode 末尾，执行以下代码保证 MMU 使用新页表运行：

   代码块

```
write_csr(satp, MAKE_SATP(mm->pgdir));
sfence.vma;
```

执行经过

当一个用户进程被创建完成后，ucore 的调度器会把其标记为 `RUNNABLE`。当调度器选择它运行时，该进程进入 `RUNNING` 状态，随后经历以下步骤，最终执行用户程序的第一条指令：

1. **调度器选择并切换到该进程（switch_to）**

   调度器调用 `proc_run(next)`，该函数执行：

   - 切换当前 `current` 指针
   - 切换页表（`satp`）
   - 调用 `switch_to` 切换内核栈、保存/恢复上下文

2. **内核准备返回用户态执行（在系统调用/时钟中断结束处）**

   返回前内核会把该进程的 trapframe restore 到 CPU：

   - `sepc ← tf->epc`（用户程序入口）
   - `sscratch ← 内核栈地址`
   - `sstatus` 根据 tf->status 设定（SPP=0 表示要进入用户态）

3. **执行 sret，CPU 权限从 S 模式切换到 U 模式**

   `sret` 指令做三件事：

   a. 把 SPP=0 表示的目标模式切换到用户态

   b. 把 sepc 的值加载到 PC（执行开始地址）

   c. 根据 SPIE 设置用户态的中断使能

   此时 CPU 正式离开内核态。

4. **用户程序开始执行自己的第一条指令**

   `PC = elf->e_entry`

   然后用户程序在它的虚拟地址空间中执行：

   - 使用自己的用户栈（USTACKTOP）
   - 所有地址访问都受页表保护
   - 若进程执行系统调用/异常，则再次进入 trap 流程

这标志着 ucore 成功完成了一次从 “创建用户进程 → 调度 → 执行用户代码” 的完整过程。

练习二

代码块

```
// (1) 获取源页面的内核虚拟地址
void *src_kvaddr = page2kva(page);

// (2) 获取目标页面的内核虚拟地址
void *dst_kvaddr = page2kva(npage);

// (3) 复制页面内容（整页复制，大小为 PGSIZE）
memcpy(dst_kvaddr, src_kvaddr, PGSIZE);

// (4) 建立目标进程的虚拟地址 start 到新物理页 npage 的映射
ret = page_insert(to, npage, start, perm);
```

`copy_range` 实现采用“逐页复制”的方式，将父进程用户空间中的有效页面复制到子进程中。实现过程中，函数首先对传入的地址范围进行合法性检查，然后使用 `get_pte` 按页扫描父进程页表，跳过未映射区域以提升效率。对于每一个有效页，函数通过 `pte2page` 获取其对应的物理页，并调用 `alloc_page` 为子进程分配新的物理页。利用 `page2kva` 将物理页转换为可访问的内核虚拟地址后，使用 `memcpy` 完整复制父页内容。在复制完成后，使用 `page_insert` 将新页正确映射到子进程页表中，继承父页的用户态权限。

核心流程如下：

1.参数合法性检查

代码块

```
assert(start % PGSIZE == 0 && end % PGSIZE == 0);
assert(USER_ACCESS(start, end));
```

1. `start` 与 `end` 必须按页对齐，否则无法按页复制。
2. 复制范围必须在用户空间，否则可能破坏内核地址空间。

2.逐页扫描父页表项

代码块

```
pte_t *ptep = get_pte(from, start, 0);
if (ptep == NULL) {
    start = ROUNDDOWN(start + PTSIZE, PTSIZE);
    continue;
}
```

- 使用 `get_pte(from, start, 0)` 查询父页表项，不创建页表。

- 若 pte 不存在，对应的一级页表中不存在该段，则可直接跳到下一个 PTSIZE（4MB）区域，提升效率。

3.判断该页是否有效（PTE_V）

```
代码块
1   if (*ptep & PTE_V) {
```

- 仅当父进程该页有效（被实际使用）时才需要复制，否则跳过。

4.为子进程确保页表存在

```
代码块
1   nptep = get_pte(to, start, 1);
2   if (nptep == NULL) {
3       return -E_NO_MEM;
4   }
```

- 子进程对应的二级页表必须存在，否则需要创建。
- 若创建失败则返回内存不足。

5.获取父页的权限与对应 Page 结构

```
代码块
1   uint32_t perm = (*ptep & PTE_USER);
2   struct Page *page = pte2page(*ptep);
3   assert(page != NULL);
```

- `perm` 继承用户态权限位（读写、用户可访问等）。
- `pte2page` 得到物理页对应 Page 结构，以便获取内核映射地址。

6.为子进程分配新物理页

```
代码块
1   struct Page *npage = alloc_page();
2   assert(npage != NULL);
```

- 在非 COW 的实现中必须为子进程分配新物理页。

- 若分配失败直接断言。

7.计算源页与目标页的内核虚拟地址

代码块

```
void *src_kvaddr = page2kva(page);
void *dst_kvaddr = page2kva(npage);
```

8.拷贝整页数据

代码块

```
bool intr_flag;
local_intr_save(intr_flag);

memcpy(dst_kvaddr, src_kvaddr, PGSIZE);

local_intr_restore(intr_flag);
```

1. `memcpy` 需拷贝 4KB 整页内容。
2. 使用 `local_intr_save()` 与 `restore()` 保护临界区，避免中断导致页内容不一致。
3. 保证复制过程原子性。

9.将新物理页插入子页表中

代码块

```
int ret = page_insert(to, npage, start, perm);
assert(ret == 0);
```

- `page_insert` 完成从虚拟地址到物理页的映射。
- 若插入失败（如已有映射），需断言终止。
- 权限继承父进程。

10.移动到下一页

代码块

```
start += PGSIZE;
```

- 每次循环复制一页，递增地址继续扫描。

练习三

fork 的执行流程

用户态调用：`int pid = fork();`，随后流程为：

（1）用户态 → trap（系统调用）→ 内核态

- 执行 `ecall`
- trap 进入内核的 `exception_handler`
- 内核解析 syscall number = SYS_fork

（2）内核态执行 do_fork

主要步骤：

- **创建子进程的 proc_struct**
- **复制父进程的内核栈、trapframe、线程上下文**
- **复制父进程页表并建立 CoW 或直接复制内存（不同实验版本差异）**
- 将子进程的 **trapframe->a0 设置为 0**
  → 让子进程的 fork 返回值变为 0
- 修改父进程的返回值为 **子 pid**
- 把子进程放入可调度队列

（3）内核返回用户态（通过 sret）

返回父进程 → fork 返回子 pid

子进程第一次被调度时 → fork 返回 0

exec 的执行流程

用户态调用：`exec("hello");`，流程为：

（1）用户态 ecall → 进入内核

syscall number = SYS_exec

（2）内核态执行 do_execve / load_icode

关键操作：

- 丢弃当前进程旧的地址空间 mm
- 为进程创建新的 mm_struct
- 根据 ELF program headers：
  - 建立代码段/数据段页表映射
  - 加载文件内容到用户虚拟地址
- 分配新的用户栈
- **重建 trapframe（设置 sp、epc=ELF entry、清 SPP）**
- 切换页表 satp

（3）sret 返回用户态

返回到新 ELF 程序的入口（_start）

wait 的执行流程

用户态调用：`wait(&status);`

（1）用户态 → ecall → 内核态

syscall = SYS_wait

（2）内存态执行 do_wait

逻辑：

- 在进程表中寻找某个子进程，其 state == ZOMBIE
- 若找到：
  - 回收它的内存、页表、内核栈
  - 获取 exit code 并写入用户提供的 status
  - 返回子进程 pid
- 若没找到：
  - 将当前进程置为 SLEEPING
  - 让调度器切换到其他进程

（3）内核返回用户态

- 父进程再次被唤醒，wait 返回子 pid

exit 的执行流程

用户态调用：`exit(0);`

（1）用户态 → ecall → 内核态

syscall = SYS_exit

（2）内核态执行 do_exit

操作：

- 设置当前进程状态为 **ZOMBIE**
- 记录退出码 exit code
- 释放用户地址空间（mm）
- 唤醒父进程（可能在 wait）
- 调度器切换到其它进程（进程不再返回用户态）

（3）该进程不会再返回用户态

直到父进程 wait 回收它。

用户态和内核态对比

系统调用	用户态部分	内核态部分
fork	fork() 调用 + 返回值处理	创建子进程、复制页表、复制 trapframe、子进程 a0=0
exec	exec("file") 调用	创建新地址空间、加载 ELF、设置 trapframe、切页表
wait	用户传递 status 地址	查找 zombie、回收资源、睡眠父进程、唤醒父进程
exit	exit(code)	设置僵尸状态、唤醒父进程、释放地址空间

ucore 用户进程的生命周期

代码块

```
                +-------------------+
                |    NEW（创建态）    |
                +-------------------+
                          |
                          | do_fork / do_execve
                          v
                +-------------------+
                |  READY（就绪态）    |
                +-------------------+
```

```
                          |
                          | 调度器 sched() / proc_run()
                          v
                +-------------------+
                | RUNNING (运行态)  |
                +-------------------+
            +---------+---------+
            |                   |
     (被抢占/主动让出)   (用户态 ecall / trap)
            |                   |
            v                   v
    +----------------+    +--------------------+
    | READY(再调度)  |    |   BLOCKED(阻塞态)   |
    +----------------+    +--------------------+
                               |
                               | 等待资源满足 / 唤醒
                               v
                      +-------------------+
                      |   READY(可运行)   |
                      +-------------------+
                               |
                               v
                          (调度运行)
                               |
                               v
                +---------------------------+
                |     EXITED/ZOMBIE(退出态) |
                +---------------------------+
                               |
                               | 父进程 wait()
                               v
                +---------------------------+
                |      回收并彻底删除       |
                +---------------------------+
```

Challenge1：COW机制

我们在练习二代码的基础上实现COW机制：

代码块

```
int copy_range(pde_t *to, pde_t *from, uintptr_t start, uintptr_t end, bool
share)
// (1) 参数说明
// to: 子进程的页目录指针
// from: 父进程的页目录指针
```

```
// start/end: 要复制的虚拟地址范围
// share: 是否共享（在COW中始终为true）
{
    //（2）地址检查：确保地址是页对齐的，且位于用户地址空间
    assert(start % PGSIZE == 0 && end % PGSIZE == 0);
    assert(USER_ACCESS(start, end));

    //（3）核心循环逻辑：逐页处理父进程地址空间中的每个页面
    do {

        //（3_1）获取父进程中该虚拟地址的页表项，如果父进程没有映射此页，就跳过整个页表
        pte_t *ptep = get_pte(from, start, 0), *nptep; //ptep和nptep都是指向页表项的指针
        if (ptep == NULL) {
            start = ROUNDDOWN(start + PTSIZE, PTSIZE);
            continue;
        }

        //（3_2）处理有效页面
        if (*ptep & PTE_V) { //检查父进程页面是否有效
            if ((nptep = get_pte(to, start, 1)) == NULL) { //为子进程创建页表项（参数1表示如不存在则创建）
                return -E_NO_MEM; //error_没内存
            }

            struct Page *page = pte2page(*ptep); //从页表项指针获取对应的物理页管理结构

            if (*ptep & PTE_W) {
                // ===== 关键修改：只对可写页面设置COW =====
                page_ref_inc(page); //增加物理页面的引用计数

                // 计算新的PTE值(去掉W,加上COW)
                pte_t pte_flags = (*ptep) & 0x3FF;  // 保留父进程页表项的低10位（标志位）
                pte_t new_pte = ((*ptep) & ~((pte_t)0x3FF)) |  // 保留高位的物理页号（PPN）
                                ((pte_flags & ~PTE_W) | PTE_COW);
                                // 修改标志位：~PTE_W表示清楚写权限，这是触发COW的关键，PTE_COW是自定义的COW标志位

                // ===== 重要：不修改父进程,只修改子进程 =====
                *nptep = new_pte; //只设置子进程的页表项，父进程的页表项保持不变，仍保持写权限
                // 这样父进程可以继续写入，而子进程的写操作会报错

                // 只刷新子进程的TLB
```

```
45                  tlb_invalidate(to, start);
46
47              } else {
48                  // 只读页面(TEXT段)直接共享
49                  page_ref_inc(page);
50                  *nptep = *ptep; // 子进程的页表项指针就等同于父进程的
51                  // 这里不用设置COW，因为这些页面本来就不能写
52              }
53          }
54          start += PGSIZE; //页对齐的地址递增
55      } while (start != 0 && start < end);
56
57      return 0;
58  }
```

总体概述

`copy_range()` 函数负责在进程 `fork()` 时复制父进程的地址空间到子进程。基于练习二代码的关键改进是：对于可写页面，不是立即复制物理页面，而是**先共享物理页面并标记为COW，等到实际写入时才触发页错误进行真正的复制**。

COW的工作流程总结

1. **Fork时**：
   - 可写页面：父子共享，子进程页表项去掉写权限+添加COW标志
   - 只读页面：父子共享，完全复制页表项
2. **子进程尝试写入时**：
   - CPU检测到无写权限 → 触发缺页异常 `page fault`
   - 页错误处理程序看到COW标志 → 执行真正的复制：
     i. 分配新物理页面
     ii. 复制原页面内容
     iii. 更新子进程页表项：设置写权限，清除COW标志
     iv. 原页面引用计数减1
3. **父进程写入时**：
   - 正常写入（父进程页表项仍有写权限）
   - 如果子进程还未写入：父子继续共享，子进程的COW状态不变
   - 如果子进程已写入：父子使用不同的物理页面，互不影响

其他函数的修改

代码块

```
// 页面错误总处理函数
static int pgfault_handler(struct trapframe *tf) {
    uintptr_t addr = tf->tval;          // 发生错误的虚拟地址
    uint32_t error_code = tf->cause;    // 错误原因

    if (current == NULL) { //表示内核线程缺页（不可能啊！）所以直接panic
        print_trapframe(tf);
        panic("page fault in kernel!"); // current是当前运行进程的PCB指针
    }

    if (current->mm == NULL) { //表示内核线程缺页（不可能啊！）所以直接panic
        print_trapframe(tf);
        panic("page fault in kernel thread!"); // current->mm是进程的内存管理结构
    }

    // 检查是否是写时复制触发的页面错误
    pde_t *pgdir_va = current->mm->pgdir;       // 进程页目录
    pte_t *ptep = get_pte(pgdir_va, addr, 0);  // 获取页表项

    if (ptep != NULL && (*ptep & PTE_V)) {      // 页表项存在且有效

        // 检查COW标志 且 是写操作引起的缺页错误
        if ((*ptep & PTE_COW) && (error_code == CAUSE_STORE_PAGE_FAULT)) {
            int ret = do_cow_page_fault(current->mm, error_code, addr);
            return ret;
        }
    }

    cprintf("page fault at 0x%08x: %c/%c\n", addr,
            (error_code == CAUSE_LOAD_PAGE_FAULT) ? 'R' : 'W',
            (tf->status & SSTATUS_SPP) ? 'K' : 'U');

    return -E_INVAL; // 不是COW错误，返回无效参数错误
}

// COW页面错误处理函数——执行真正的COW复制操作
static int do_cow_page_fault(struct mm_struct *mm, uint32_t error_code,
uintptr_t addr) {
    int ret = 0;
    pte_t *ptep = NULL;
    uintptr_t la = ROUNDDOWN(addr, PGSIZE);   // la = 页面对齐的地址

```

```
    ptep = get_pte(mm->pgdir, la, 0);          // ptep是指向虚拟地址 la 对应的页表项的指针
    if (ptep == NULL || !(*ptep & PTE_V)) {
        return -E_INVAL;
    }

    pte_t old_pte_value = *ptep;               // 保存原页表项

    struct Page *old_page = pte2page(*ptep);   // 从页表项的值 → 对应物理页的Page结构指针
    int ref_count = page_ref(old_page);        // 获取引用计数

    //（1）只有一个进程引用,直接恢复写权限（其他进程已经执行了COW，只剩当前进程使用）
    if (ref_count == 1) {
        pte_t new_pte = (old_pte_value | PTE_W) & ~PTE_COW;
        *ptep = new_pte;

        // 强制刷新TLB
        asm volatile("sfence.vma zero, %0" :: "r"(la) : "memory");
        asm volatile("fence" ::: "memory");

        return 0;
    }

    //（2）多个进程共享,需要真正复制页面
    struct Page *new_page = alloc_page();    // 分配新物理页
    if (new_page == NULL) {
        return -E_NO_MEM;
    }
    uintptr_t src_kva = (uintptr_t)page2kva(old_page); // 复制页面内容
    uintptr_t dst_kva = (uintptr_t)page2kva(new_page);
    memcpy((void*)dst_kva, (void*)src_kva, PGSIZE); // 复制4KB数据
    page_ref_dec(old_page); //原页面引用减一

    //（3）更新页表项
    uint32_t perm = (old_pte_value & (PTE_U | PTE_R | PTE_X)) | PTE_W; // 计算新权限
    set_page_ref(new_page, 1); // 修改PTE
    *ptep = pte_create(page2ppn(new_page), PTE_V | perm);

    // 强制刷新TLB，确保操作顺序
    asm volatile("sfence.vma zero, %0" :: "r"(la) : "memory");
    asm volatile("fence" ::: "memory");

    return 0;
}
```

这两个函数共同实现了COW机制：

1. `pgfault_handler`：**识别器**
   - 快速判断是否COW错误
   - 不是COW错误就交给标准处理
   - 是COW错误就交给 `do_cow_page_fault`。
2. `do_cow_page_fault`：**执行器**
   - 根据引用计数选择策略
   - 管理物理页复制和引用计数
   - 更新页表映射

测试样例说明

为测试所编写的COW机制，我们引入了两个新的测试样例： `cowtest.c` 和 `dirtycow_test.c`。

`cowtest.c`

代码块

```
// user/cowtest.c
#include <stdio.h>
#include <ulib.h>

#define TEST_SIZE 10

int main(void) {
    cprintf("COW Test Starting...\n");

    static int data[TEST_SIZE];   // 测试数据结构，10个int = 40字节，通常一个页面4KB，data数组只占很小部分

    for (int i = 0; i < TEST_SIZE; i++) {   //父进程初始化数组
        data[i] = i * 100;   // [0, 100, 200, ..., 900]
    }
    cprintf("Parent: initialized data\n");
    // 此时:
    // 物理页A: [0, 100, 200, 300, 400, 500, 600, 700, 800, 900, ...]
    // 父进程PTE: 指向物理页A，有写权限(W=1)

    int pid = fork();   // COW机制在这里生效，fork()函数是系统调用，创建子进程

    // 物理页A: [0, 100, 200, ..., 900]  ← 被两个进程共享
    //          ↗                    ↖
    // 父进程PTE(W=1)          子进程PTE(W=0, COW=1)
```

```
25      // 引用计数: page.ref = 2
26
27      if (pid == 0) { //OS内核硬性保证父进程 pid > 0，子进程 pid == 0，如果出错则 pid
    < 0
28          // 子进程: 只读操作，不触发COW
29          cprintf("Child: reading parent's data...\n");
30          int sum = 0;
31          for (int i = 0; i < TEST_SIZE; i++) {
32              sum += data[i];   // 只是读取，页表项W=0但R=1，允许读取
33          }
34          // sum = 0+100+200+...+900 = 4500 ✓
35          cprintf("Child: sum before write = %d\n", sum);
36
37          if (sum != 4500) {
38              cprintf("Child: ERROR - sum should be 4500\n");
39              exit(-1);
40          }
41
42          // 子进程写入操作 - 触发COW
43          cprintf("Child: writing data (trigger COW)...\n");
44          for (int i = 0; i < TEST_SIZE; i++) {
45              data[i] = i * 200;
46          }
47          /*
48          1. 子进程执行: data[0] = 0 * 200 = 0
49          2. CPU检测: 页表项PTE_W=0，无写权限
50          3. 触发页面错误（Page Fault）
51          4. 缺页处理程序检查: PTE_COW=1 → 是COW页面
52          5. 执行COW处理:
53             a. 分配新物理页B
54             b. 复制A的内容到B
55             c. 更新子进程PTE指向B，设置W=1，清除COW
56             d. 原页面A引用计数减为1
57          6. 恢复执行，写入成功
58          */
59          /*
60          写入后的内存状态:
61          物理页A: [0, 100, 200, ..., 900]    ← 仅父进程使用，ref=1
62          物理页B: [0, 200, 400, ..., 1800]   ← 子进程独享，ref=1
63          */
64
65          // 再次读取，求和验证子进程的写入结果
66          sum = 0;
67          for (int i = 0; i < TEST_SIZE; i++) {
68              sum += data[i];
69          }
70          // sum = 0+200+400+...+1800 = 9000 ✓
```

```
71          cprintf("Child: sum after write = %d\n", sum);
72
73          if (sum != 9000) {
74              cprintf("Child: ERROR - sum should be 9000\n");
75              exit(-2);
76          }
77
78          exit(0);
79      } else if (pid > 0) {
80          int exit_code = 0;
81          waitpid(pid, &exit_code);  // 父进程等待子进程结束
82
83          if (exit_code == 0) {
84              cprintf("Child completed successfully\n");
85          } else {
86              cprintf("Child failed with code %d\n", exit_code);
87          }
88
89          cprintf("Parent: checking data after child...\n");
90          // 验证父进程的数据未受影响
91          int sum = 0;
92          for (int i = 0; i < TEST_SIZE; i++) {
93              sum += data[i];   // 读取的是物理页A，原始数据
94          }
95          // sum = 0+100+200+...+900 = 4500 ✓
96          cprintf("Parent: sum = %d (should be 4500)\n", sum);
97
98          if (sum == 4500 && exit_code == 0) {
99              cprintf("COW Test PASSED!\n");
100         } else {
101             cprintf("COW Test FAILED!\n");
102         }
103     } else {
104         cprintf("fork failed\n");
105         return -1;
106     }
107
108     return 0;
109 }
```

`fork()` 后分裂，父进程和子进程交替输出，流程如下：

代码块

```
1  时间轴:
2  t0: 【父进程】输出 "COW Test Starting..."
```

```
t1: 【父进程】输出 "Parent: initialized data"
t2: fork()分裂成两个进程
    ├─ 【父进程】继续，但暂时不输出（在waitpid等待）
    └─ 【子进程】开始执行，输出所有"Child: ..."内容
t3: 【子进程】exit(0)结束
t4: 【父进程】waitpid返回，继续输出"Child completed successfully..."
t5: 【父进程】输出剩余内容
```

测试后的输出如下（由于篇幅问题，这里只显示关键输出）：可以看到输出了正确语句。

代码块

```
kernel_execve: pid = 2, name = "cowtest".
Breakpoint
COW Test Starting...
Parent: initialized data
Child: reading parent's data...
Child: sum before write = 4500
Child: writing data (trigger COW)...
Child: sum after write = 9000
Child completed successfully
Parent: checking data after child...
Parent: sum = 4500 (should be 4500)
COW Test PASSED!
all user-mode processes have quit.
init check memory pass.
```

`dirtycow_test.c`

什么是 `Dirty COW` ?

Dirty COW 是Linux内核中的一个著名安全漏洞，该漏洞不是正常的COW功能，而是一个**利用COW机制的竞态条件漏洞**。

漏洞本质：

- 正常COW：写时复制，保护进程间内存隔离
- Dirty COW漏洞：利用内核中的竞态条件，让只读内存页面被恶意修改

Dirty COW攻击步骤：

1. 进程A：通过 `mmap` 映射一个只读文件到内存
2. 进程A： `fork()` 创建进程B（共享该只读页面）
3. 【竞态条件开始】

进程A：不断调用 `madvise(MADV_DONTNEED)` → 告诉内核"这个页面不重要"

进程B：不断写入该页面 → 触发COW处理

（这里值得注意：因为 `mmap` 时用了 `MAP_PRIVATE` ，即使原文件是只读的，对私有映射的写入应该触发COW， `fork` 之后进程B的那个页面自动带有COW标志，所以可写！）

4. 关键：如果两个操作恰好同时发生：
   - `madvise` 让内核认为页面可以被丢弃
   - COW处理正在分配新页面
   - 内核可能错误地将写入应用到原只读页面！
5. 结果：只读页面被非法修改！普通用户提升到root权限

代码块

```c
// user/dirtycow_test.c
#include <stdio.h>
#include <ulib.h>
#include <string.h>

int main(void) {
    cprintf("DirtyCOW vulnerability test\n");

    // 使用静态数组代替动态分配，确保在一个页面内
    static char data[4096];

    // 初始化数据
    const char *original = "ORIGINAL DATA";
    for (int i = 0; original[i] != '\0'; i++) {
        data[i] = original[i];
    }
    data[13] = '\0';  // 确保字符串结束
    // 现在：data[] = "ORIGINAL DATA"
    // 物理页面P：包含这个字符串，父进程有写权限

    // fork创建子进程
    int pid = fork();
    // fork后：父子共享页面P
    // 父进程PTE：W=1
    // 子进程PTE：W=0，COW=1

    if (pid == 0) {
        // 子进程尝试多次写入，触发竞态条件
        for (int i = 0; i < 100; i++) {
            data[0] = 'M';  // 触发COW
        }
/*
潜在竞态场景时间线：
```

```
34  t0: 子进程第一次写入 → 触发COW
35      CPU: 检测W=0 → 触发缺页 → 进入内核处理
36  t1: 内核开始COW处理:
37      1. 获取原页面锁
38      2. 分配新页面Q
39      3. 复制P→Q
40      4. 更新子进程PTE指向Q
41      5. 释放原页面锁
42  t2: 子进程第二次写入（循环中）
43      如果发生在t1的步骤4之前:
44      - 可能还在使用旧的映射（指向P）
45      - 但内核认为正在处理COW
46      - 可能导致未定义行为
47  */
48
49          // 检查是否修改成功
50          if (data[0] == 'M') {
51              cprintf("Child: data modified (expected behavior)\n");
52          }
53
54          exit(0);
55      } else if (pid > 0) {
56          int exit_code = 0;
57          waitpid(pid, &exit_code);  // 等待子进程结束
58
59          // 父进程检查数据是否被破坏
60          int is_original = 1;
61          for (int i = 0; original[i] != '\0'; i++) {
62              if (data[i] != original[i]) {
63                  is_original = 0;  // 数据被破坏
64                  break;
65              }
66          }
67
68          if (is_original) {
69              cprintf("Test completed - no corruption should occur\n");
70          } else {
71              cprintf("ERROR: parent data corrupted!\n");
72          }
73      } else {
74          cprintf("fork failed\n");
75          return -1;
76      }
77
78      return 0;
79  }
```

我们的上述代码不是Dirty COW攻击，只是**测试COW机制的竞态条件安全性**。该测试的测试输出如下（只显示关键部分）：

```
代码块
1  kernel_execve: pid = 2, name = "dirtycow_test".
2  Breakpoint
3  DirtyCOW vulnerability test
4  Child: data modified (expected behavior)
5  Test completed - no corruption should occur
6  all user-mode processes have quit.
7  init check memory pass.
```

可以看到，我们的COW实现正确处理了多次写入，**没有竞态条件问题**。真实的COW攻击还需要引入另一进程，让其不断调用 `madvise(addr, MADV_DONTNEED)` ，与触发COW的进程并发执行，增大竞态窗口。

测试得分截图

基础版：

```
badsegment:              (2.0s)
  -check result:                             OK
  -check output:                             OK
divzero:                 (1.7s)
  -check result:                             OK
  -check output:                             OK
softint:                 (1.6s)
  -check result:                             OK
  -check output:                             OK
faultread:               (1.8s)
  -check result:                             OK
  -check output:                             OK
faultreadkernel:         (2.0s)
  -check result:                             OK
  -check output:                             OK
hello:                   (1.8s)
  -check result:                             OK
  -check output:                             OK
testbss:                 (1.8s)
  -check result:                             OK
  -check output:                             OK
pgdir:                   (1.6s)
  -check result:                             OK
  -check output:                             OK
yield:                   (2.0s)
  -check result:                             OK
  -check output:                             OK
badarg:                  (1.7s)
  -check result:                             OK
  -check output:                             OK
exit:                    (1.7s)
  -check result:                             OK
  -check output:                             OK
spin:                    (4.5s)
  -check result:                             OK
  -check output:                             OK
forktest:                (1.7s)
  -check result:                             OK
  -check output:                             OK
Total Score: 130/130
```

COW机制版：

```
badsegment:              (2.0s)
  -check result:                             OK
  -check output:                             OK
divzero:                 (1.1s)
  -check result:                             OK
  -check output:                             OK
softint:                 (1.5s)
  -check result:                             OK
  -check output:                             OK
faultread:               (2.5s)
  -check result:                             OK
  -check output:                             OK
faultreadkernel:         (2.2s)
  -check result:                             OK
  -check output:                             OK
hello:                   (1.9s)
  -check result:                             OK
  -check output:                             OK
testbss:                 (2.6s)
  -check result:                             OK
  -check output:                             OK
pgdir:                   (1.6s)
  -check result:                             OK
  -check output:                             OK
yield:                   (2.1s)
  -check result:                             OK
  -check output:                             OK
badarg:                  (1.5s)
  -check result:                             OK
  -check output:                             OK
exit:                    (1.9s)
  -check result:                             OK
  -check output:                             OK
spin:                    (5.0s)
  -check result:                             OK
  -check output:                             OK
forktest:                (2.0s)
  -check result:                             OK
  -check output:                             OK
cowtest:                 (2.1s)
  -check result:                             OK
  -check output:                             OK
dirtycow_test:           (2.2s)
  -check result:                             OK
  -check output:                             OK
Total Score: 150/150
```

Challenge2

1.用户程序是何时被预先加载到内存中的?

用户态应用程序**在编译内核镜像阶段就已经作为数据段一起打包进内存中**。

其过程如下：

1. `make` 过程会把所有 `user/*.c` 编译为 ELF 格式的用户程序。
2. 这些 ELF 程序会被链接脚本安排放置在内核镜像的末尾。
3. 当 QEMU 启动并加载 `kernel` 镜像时，这些用户程序就随内核一起被装入物理内存。

2.与常见操作系统的加载方式有什么区别?

项目	ucore（教学系统）	Linux / Windows（真实 OS）
用户程序存放位置	编译内核时打包在内核镜像内存中	存储在磁盘文件系统中
用户程序加载时间	**内核启动时一次性加载到内存**	exec 时从磁盘按需加载
exec 的实现	直接从内存中的 ELF 模板复制到用户空间	读取 ELF 文件、建立 VMA、按需页缺页加载
文件系统依赖	不依赖文件系统（lab5 无 FS）	强依赖 FS（ext4, NTFS 等）
程序数量	小量固定测试程序	任意可执行文件
安全隔离/权限	简化实现，不涉及权限管理	完整的权限控制与文件访问控制

ucore 是预加载用户程序到内存，真实 OS 则是按需从磁盘加载可执行文件。

分支任务1（lab2）：gdb 调试页表查询过程

见另一个报告

分支任务2（lab5）：gdb 调试系统调用以及返回

首先按照顺序打开三个终端

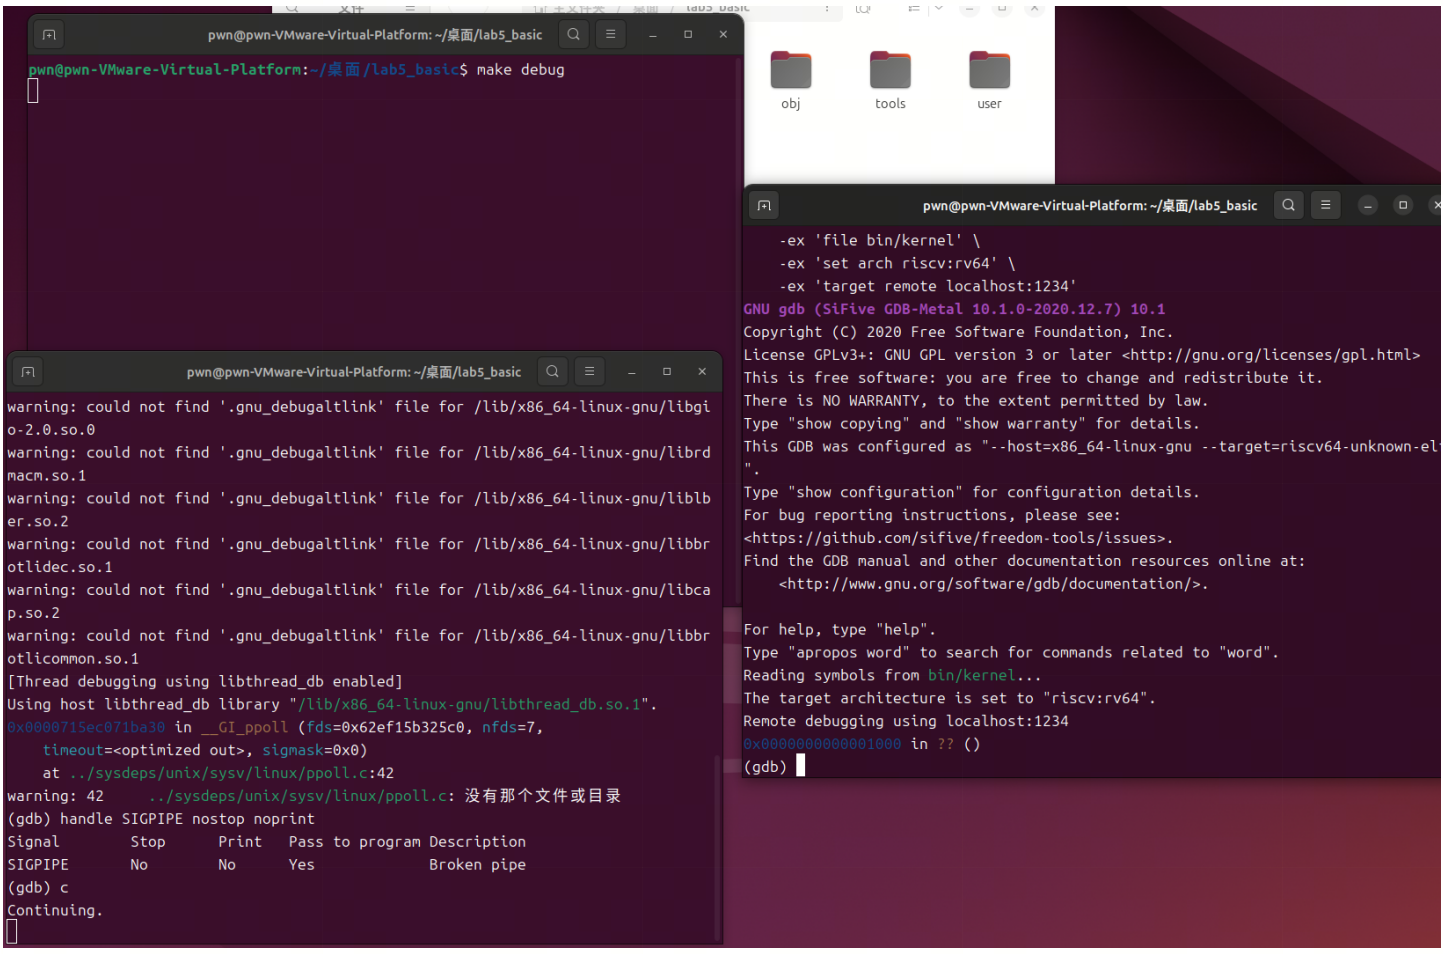

- 左上角终端1用于启动新编译的调试版QEMU，并暂停在初始状态。

- 左下角终端2用于调试QEMU进程，主要用于
  - 观察 QEMU 如何翻译 ecall/sret 指令
  - 观察 QEMU 如何处理异常、切换特权级、写 CSR
- 右侧终端3用于调试ucore内核

由于要调试用户程序，因此需要手动加载用户程序的符号 `add-symbol-file obj/__user_exit.out`

加载后就可以在用户空间代码里打断点，比如在 `syscall` 函数处

代码块

```
(gdb) b user/libs/syscall.c:19
(gdb) c                    # 放行，直到第一次调用 syscall
```

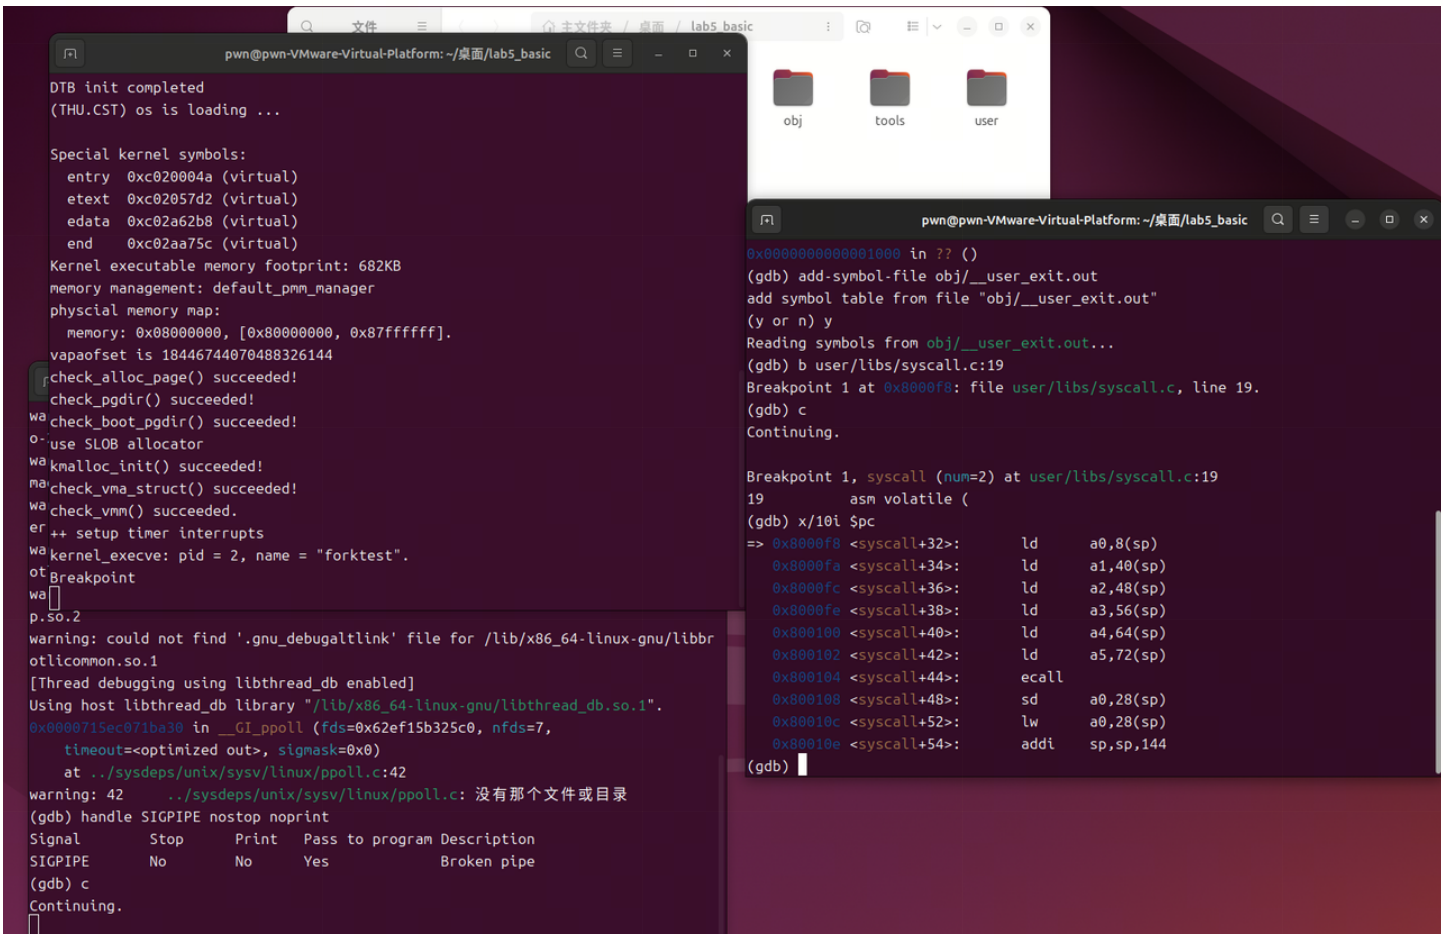

可以看到用户程序在 0x800104 处执行 ecall ，把这个地址告诉终端2，让 QEMU 只在翻译这条 ecall 时停住。

接下来回到终端2，先按 `Ctrl + C` 打断 QEMU，让 gdb 回到 `(gdb)` 提示符。然后在翻译函数处打上断点 `b riscv_tr_translate_insn` ，继续执行

代码块

```
(gdb) b riscv_tr_translate_insn
```

```
2    (gdb) c
```

让其只在翻译 PC=0x800104 时停止 `condition 1 ctx->base.pc_next == 0x800104`，继续执行

此时终端3还停在 ecall 之前的 C 语句，再重复执行 `si`，发出ecall指令，此时发生的事情：

- guest 角度：CPU 执行 `ecall`
- QEMU 角度：把这条 ecall 翻译成 TCG 或执行已经翻译好的 TB

终端2会在翻译这条 ecall 指令时自动暂停

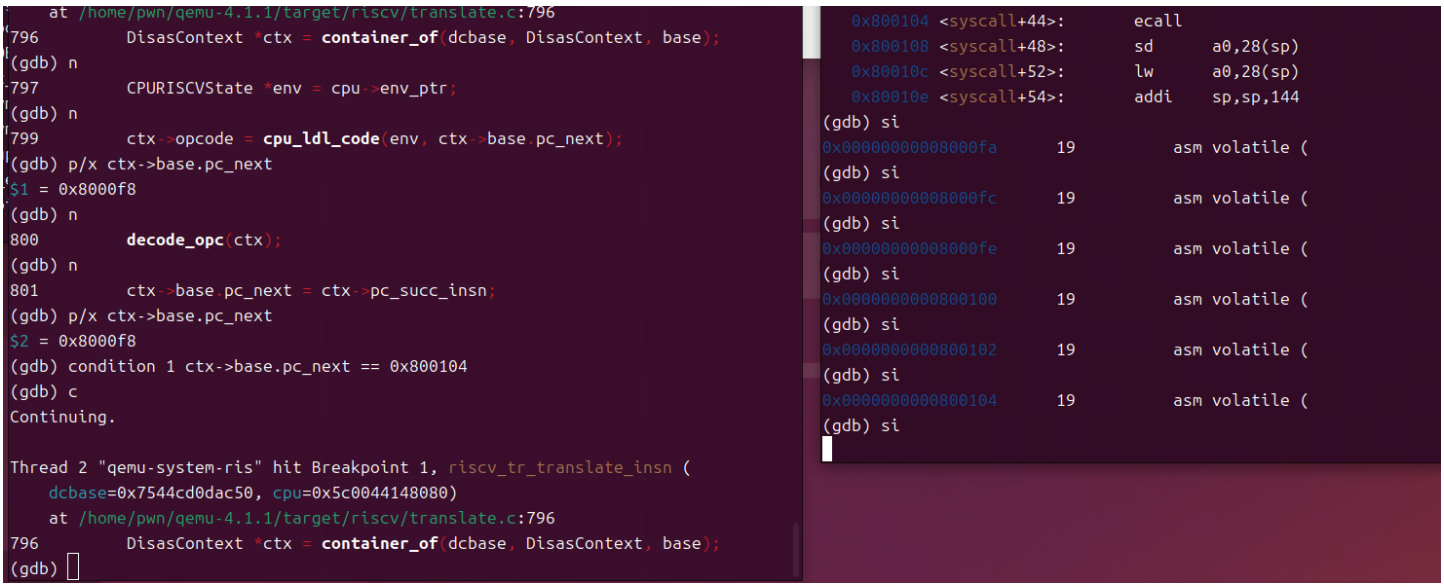

可以看到单步C代码和调用栈，例如图中 `decode_opc(ctx);` 里识别 opcode 是 SYSTEM、funct3/imm 对应 ECALL

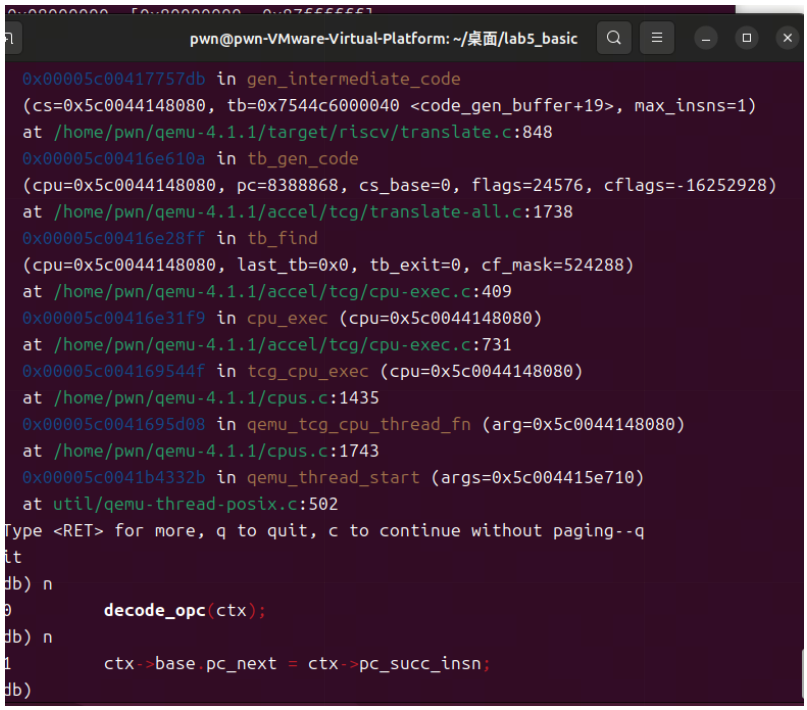

随后在终端2继续执行，抛出异常，CPU 进入内核 trap。此时 PC 已经不再是 0x800104，而是跳到了内核的 trap 入口（ S 态），并且CSR 也被写好。

```
(gdb) si
0xffffffffc0200f38 in __alltraps () at kern/trap/trapentry.S:123
123         SAVE_ALL
(gdb) i r pc
pc             0xffffffffc0200f38       0xffffffffc0200f38 <__alltraps+4>
(gdb) p/x $sepc
$1 = 0x800104
(gdb) p/x $scause
$2 = 0x8
(gdb) p/x $sstatus
$3 = 0x8000000000046020
(gdb)
```

这就是从用户态执行 ecall → QEMU 模拟硬件 → 进入内核态的流程。

接下来是从内核返回用户态的调试流程

先在终端3中设置断点 `b __trapret` 并执行，使用 `disassemble` 展示全部反汇编指令，可以看到sret的位置

```
   0xffffffffc0200ff2 <+78>:    ld      t4,232(sp)
   0xffffffffc0200ff4 <+80>:    ld      t5,240(sp)
   0xffffffffc0200ff6 <+82>:    ld      t6,248(sp)
   0xffffffffc0200ff8 <+84>:    ld      sp,16(sp)
   0xffffffffc0200ffa <+86>:    sret
End of assembler dump.
```

继续打断点并执行，可以使用 `x/3i $pc` 看到暂停在sret之前

```
(gdb) b *0xffffffffc0200ffa
Breakpoint 4 at 0xffffffffc0200ffa: file kern/trap/trapentry.S, line 133.
(gdb) c
Continuing.

Breakpoint 4, __trapret () at kern/trap/trapentry.S:133
133         sret
(gdb)
```

可以查看当前CSR

```
(gdb) p/x $sepc
$4 = 0x800108
(gdb) p/x $sstatus
$5 = 0x8000000000046020
(gdb) i r pc
pc             0xffffffffc0200ffa       0xffffffffc0200ffa <__trapret+86>
```

接下来继续执行si，pc 从 `0xffffffffc0200ffa` 跳到了 `0x800108`

并且由于 `sret` 已经带回 U 态用户模式 了，所以此时 QEMU 的 gdb stub 对某些 特权寄存器（CSR） 做了限制。
在 U 模式下，gdb 不允许直接访问 S 态的 `sstatus`，于是返回了 `'E14'` 错误。

```
(gdb) si
0x0000000000800108 in syscall (num=3) at user/libs/syscall.c:19
19          asm volatile (
(gdb) i r pc
pc             0x800108 0x800108 <syscall+48>
(gdb) p/x $sstatus
Could not fetch register "sstatus"; remote failure reply 'E14'
```

TCG 翻译

- QEMU 不逐条解释执行 RISC-V 指令，而是：
  - 读一段 guest 指令（一个基本块）
  - 把它们翻译成一种 **中间表示 (TCG IR)**，
  - 再把 IR 编译成本机 x86 代码，存成一个“翻译块”。
- 下次 CPU 运行到这块代码时，就直接执行已经编译好的 x86 代码，
  不再重新解释，速度更快。

在实验里：

- `riscv_tr_translate_insn`：就是把一条 RISC-V 指令转成 TCG IR的函数。
- 在这里打断点，就是在看QEMU 是如何把 ecall/sret 这类指令翻译成异常/特权切换的行为的。也就是看 **ecall/sret 指令** 被翻译后如何触发 trap/返回。

系统调用的基本流程

- 用户程序想干一件“危险又必要”的事，比如 `write`，就调用 libc/用户库里的 `syscall(...)` 函数。
- `syscall` 函数把 **系统调用号 + 参数** 放到指定寄存器里（RISC-V 约定通常是 `a0~a7`），
- `syscall` 函数使用一条特殊指令 **`ecall`**，意思是“向更高特权级求助”。
- CPU 硬件看到 `ecall` 时会：
  - 把当前 PC 保存到 `sepc`
  - 把原因写入 `scause`（例如 U-mode ecall）
  - 把一些标志写入 `sstatus`
  - 跳到内核在 `stvec` 中设置好的 trap 入口。
- 内核 trap 处理函数根据 `scause` 发现：哦，原来是系统调用，
  - 读参数，调用对应的内核服务（例如 `sys_exit`、`sys_write`）
  - 做完之后决定是否 **返回用户态**。
- 返回用户态时最后一条关键指令是 **`sret`**：
  - 从 `sepc` 取回原来的用户态 PC，
  - 恢复特权级回到 U，
  - 跳回去让用户程序继续往下执行。